

Universidad Andrés Bello
Magíster en Ciencia de Datos e Inteligencia Artificial

MCDI500

Programación para la ciencia de datos

Evaluación Sumativa 1

Fases 1 y 2

Preparación reproducible de órdenes de Compra Ágil de Valparaíso

Grupo 7

Benjamin Araya Matta

Alan Cañete Calquin

Patricio Cortez Triviño

Jorge Guaico Ortega

Docente: PENDIENTE: nombre del docente

Fecha de entrega: PENDIENTE: fecha de entrega

Versión de trabajo: 13 de septiembre de 2026

Borrador técnico para revisión del equipo

Base preparada con asistencia de Codex; revisión y aportes del equipo pendientes.

Repositorio:

<https://github.com/BenjaArayaM/proyecto-grupo7-mcdi500>

Índice

1. Introducción y contextualización	1
2. Problemática, objetivos y alcance	1
2.1. Problema y objetivo general	1
2.2. Objetivos específicos verificables	1
2.3. Supuestos y exclusiones	2
3. Fase 1: entorno y procedencia	2
3.1. Organización reproducible	2
3.2. Herramientas elegidas y versiones	3
4. Fase 2: diagnóstico de la estructura de los datos	3
4.1. Lectura y unidad de observación	3
4.2. Repeticiones y conciliación de detalle	4
4.3. Proveedores y jerarquía de rubros	5
5. Decisiones de preprocesamiento y transformación	5
5.1. Faltantes y alternativas	5
5.2. Importes, fechas y valores extremos	6
5.3. Vista transformada	6
6. Codificación funcional y validación	7
7. Control de versiones y trazabilidad	7
8. Vinculación con el mapa conceptual V2	9
9. Reflexión técnica y próximos pasos	10
Referencias	11

1. Introducción y contextualización

El proyecto estudia la preparación de datos de Compra Ágil asociados a la unidad ABASTECIMIENTO de la Municipalidad de Valparaíso. La pregunta del mapa conceptual V2 es cómo se distribuyen los montos de las órdenes de compra según proveedores, rubros y mes de envío. Responderla exige primero establecer unidades de observación, comparabilidad monetaria y calidad de la información.

La copia examinada contiene 11.177 filas y 63 columnas. El diagnóstico distingue 541 órdenes y 277 RUT proveedores, con fechas de envío entre 2025-01-06 y 2025-06-30. Una fila del archivo no equivale necesariamente a una orden ni a un ítem único. Esta diferencia afecta directamente los totales y la interpretación de cualquier gráfico posterior.

La Fase 1 define problema, objetivos y entorno; la Fase 2 obtiene, explora, prepara y valida. Esta delimitación responde a la guía y a la rúbrica suministradas (*Guía de desarrollo*, s. f.; *Rúbrica sumativa 1*, s. f.). El análisis sustantivo y la comunicación final de las fases posteriores utilizarán las salidas verificadas, ajustándose a las guías de F3 y F4 cuando estén disponibles.

Este documento presenta una base ejecutada en un entorno de validación y decisiones propuestas para revisión. No acredita aún ejecución en los cuatro equipos, una reconstrucción del entorno Windows ni la aprobación colectiva de las políticas. Esos elementos forman parte del trabajo pendiente y del historial que debe producir el equipo durante el desarrollo.

2. Problemática, objetivos y alcance

2.1. Problema y objetivo general

El problema técnico consiste en convertir una exportación que mezcla cabeceras, ítems y cotizaciones en tablas reproducibles, sin multiplicar importes ni inventar atributos faltantes. El objetivo general es preparar un entorno y un pipeline que permitan caracterizar las órdenes observadas, conservando procedencia y trazabilidad de las decisiones.

2.2. Objetivos específicos verificables

1. Documentar intérprete, dependencias, estructura y SHA-256 del original; verificar las rutas requeridas desde la raíz del proyecto.
2. Perfilar el 100 % de las columnas y medir faltantes, repeticiones, monedas, estados y cardinalidades antes de transformar.
3. Construir por código una tabla con clave `codigo00` única, conservando las órdenes observadas y separando sus relaciones con rubros.

4. Implementar conversiones y políticas justificadas de faltantes, extremos y variables derivadas; registrar parámetros e impacto.
5. Probar casos normales, límites y errores; ejecutar F1 y F2 desde kernels nuevos y relacionar sus evidencias con el informe y los commits efectivos.

2.3. Supuestos y exclusiones

Se limita el estudio a la copia adjunta y su cobertura observada. No se infieren pagos efectivos, irregularidades, causalidad, estacionalidad anual ni resultados representativos de todas las compras públicas del país.

La cabecera de una orden debe tener atributos constantes por código; el pipeline se detiene si encuentra contradicciones. Se propone usar el neto CLP informado por la fuente como medida común, sujeto a contrastar el diccionario monetario. Las órdenes con solicitud de cancelación se conservan y se identifican para una decisión posterior sobre el universo descriptivo.

El archivo contiene únicamente valores SI en `ProveedorSeleccionado`; por ello, no permite una comparación documentada entre ofertas ganadoras y perdedoras. Los montos por rubro quedan condicionados a conciliar el detalle y resolver sus multiplicidades.

3. Fase 1: entorno y procedencia

3.1. Organización reproducible

Se mantiene la estructura F1–F4 existente. El archivo original se conserva en `F1/data/raw/1874020CCompraAgil.csv`. Las salidas transformadas se generan en `F2/data/processed`. El notebook F1 reconoce el archivo sin imputar, limpiar ni exportar registros procesados.

Tabla 1: Componentes y responsabilidad técnica

Componente	Responsabilidad
<code>proyecto.json</code>	Esquema, columnas, hash y políticas parametrizadas.
<code>F1/src/entorno.py</code>	Raíz, integridad y versiones observadas.
<code>F2/src/preprocesamiento.py</code>	Funciones de diagnóstico, preparación y validación.
<code>F2/tests</code>	Pruebas de comportamiento y riesgos analíticos.
<code>evidencias</code>	Entornos, pruebas y ejecución de notebooks.
<code>informe</code>	Texto LaTeX, tablas, figura y PDF.
<code>docs</code>	Plan, bitácora, mapa y matriz de rúbrica.

El original tiene 21.743.181 bytes. Su huella, registrada en la configuración, coincide con la copia empleada para auditar el mapa V2:

[1fcbdec3161500e95a15d2af82df3d007549f2d5da9a6d0b4e6063540406be1c](#)

La ruta usa un nombre canónico; solo renombrar el adjunto no modifica sus bytes. La URL y fecha de descarga originales deben documentarse por quien obtuvo el archivo. No se sustituyen por la fecha de esta validación.

3.2. Herramientas elegidas y versiones

pandas permite declarar separador, codificación y tipos al leer el CSV (pandas Development Team, s. f.). Se utiliza para perfiles, proyecciones y relaciones entre tablas. NumPy calcula cuantiles y parámetros de escala con criterios explícitos (NumPy Developers, s. f.). Las funciones operan sobre copias o devuelven objetos nuevos, de modo que la narrativa de Jupyter no oculte mutaciones del original.

JupyterLab permite editar archivos LaTeX y visualizar PDF (Project Jupyter, s. f.). El informe se redacta como `informe.tex`; un script genera sus insumos y ejecuta tres pasadas de pdflatex. El compilador se instala mediante MiKTeX o TeX Live fuera del entorno virtual de Python.

La validación inicial utilizó Python 3.12.14 en Linux, pandas 2.2.3, NumPy 2.3.5 y Matplotlib 3.10.8. Los notebooks se ejecutaron con ipykernel en memoria, en un proceso nuevo por notebook, porque este entorno no permite abrir conexiones de Jupyter. La ejecución normal en JupyterLab de Windows sigue pendiente. Las versiones completas observadas están en los JSON de entorno; las dependencias directas de esta comprobación están en `requirements-validation.txt`.

Se preservó `requirements.txt`, previamente generado por el equipo Windows. No se afirma equivalencia ni reconstrucción comprobada entre ambos entornos. Antes de entregar, corresponde acordar versiones, revisar incompatibilidades y ejecutar desde una instalación limpia. La semilla 42 está declarada; el pipeline actual es determinista y no utiliza muestreo aleatorio.

4. Fase 2: diagnóstico de la estructura de los datos

4.1. Lectura y unidad de observación

La lectura usa punto y coma, codificación Windows-1252 y campos iniciales como texto. Los vacíos se reconocen como ausentes y los RUT no se convierten a números. La lista de 22

atributos de cabecera se declara en la configuración y se aplica con código desde el original completo.

Antes de proyectar una fila por orden se verifica que esos atributos sean constantes dentro de cada códigoOC. La prueba permite construir 541 cabeceras sin repetir sus montos. Este procedimiento no equivale a eliminar indiscriminadamente las filas repetidas del archivo.

Se observan 536 órdenes en CLP, dos en USD, dos en UTM y una en CLF. Los estados son 537 Aceptada, tres Recepción Conforme y una Solicitud de Cancelación. Se conservan todos los registros y una marca identifica las 540 órdenes de los dos primeros estados como propuesta para análisis descriptivo.

4.2. Repeticiones y conciliación de detalle

Hay 6 filas completamente idénticas adicionales, y 12 filas pertenecen a esos grupos. En 2.040 de 2.043 grupos OC–producto, la cantidad de filas coincide con el producto de las firmas distintas de ítem y cotización. En la OC 2427-699-AG25 aparecen 32 firmas de cada lado y 1.024 filas.

La coincidencia es compatible con una expansión cartesiana de relaciones, pero no demuestra por sí sola el mecanismo de exportación. La suma del campo `MontoNetoItemCLP` sobre firmas distintas concilia con la cabecera, a tolerancia absoluta de 1 CLP, en 538 órdenes.

Tabla 2: Órdenes cuyo detalle de firmas distintas no concilia

Orden	Neto OC (CLP)	Suma de firmas	Diferencia
2427-264-AG25	2.000.000,00	1.000.000,00	-1.000.000,00
2427-511-AG25	37.473,00	29.984,00	-7.489,00
2427-543-AG25	1.490.341,00	1.463.816,00	-26.525,00

Nota. Diferencia = suma de firmas menos neto de la OC. Tabla generada por código.

En 2427-264-AG25 existen dos filas idénticas de un millón de CLP y una cabecera de dos millones. Borrar una de esas filas perdería un millón del detalle. Por ello, se preservan las discrepancias, no se exporta un detalle monetario definitivo y se solicita contrastar las tres órdenes con la fuente. Conciliar numéricamente las otras órdenes tampoco prueba que se haya reconstruido cada línea real.

4.3. Proveedores y jerarquía de rubros

Se normalizan espacios, mayúsculas y puntos para comparar RUT y nombres, preservando las columnas originales. No se encontraron RUT asociados a varios nombres normalizados; por tanto, no se justifican fusiones por similitud en esta copia.

Los niveles N1, N2 y N3 contienen 53, 191 y 487 etiquetas. Hay 180 órdenes con más de un N1 y una etiqueta N2 bajo varios padres N1. Se conserva la ruta completa N1–N2–N3 en una tabla de 1.683 relaciones. Esta tabla expresa pertenencia, no asignación de montos. Sus conteos pueden solaparse.

5. Decisiones de preprocesamiento y transformación

5.1. Faltantes y alternativas

La tabla 3 diferencia el denominador de filas del denominador de órdenes. Esta distinción evita trasladar porcentajes de una unidad a otra.

Tabla 3: Ausencias en el original y en las cabeceras

Campo	Filas ausentes	OC ausentes
Actividad del proveedor	2.695 (24,11 %)	139 / 541 (25,69 %)
Región del proveedor	150 (1,34 %)	8 / 541 (1,48 %)
Impuesto específico del ítem	11.177 (100,00 %)	No aplica: campo de ítem

Nota. Filas: $n = 11.177$. OC: $n = 541$. El impuesto específico es un atributo de ítem.

Eliminar órdenes sin actividad dejaría 402 de 541; hacerlo por región dejaría 533. Imputar la moda asignaría, respectivamente, 139 u ocho atributos sin evidencia de la fuente. Se propone conservar los NA y agregar marcas y etiquetas de presentación. El impuesto específico del ítem, completamente vacío, no se interpreta como cero.




Figura 1: Faltantes de atributos de proveedor medidos por orden.

Nota. Elaboración mediante Matplotlib a partir de las métricas de F2.

El neto CLP tiene cero valores faltantes: no se aplica imputación por media, mediana ni grupo. Su varianza poblacional antes y después es 2.326.586.109.020,78 CLP²; el cambio es cero, porque ningún importe fue reemplazado o recortado.

5.2. Importes, fechas y valores extremos

La conversión de números usa coma decimal y rechaza textos o formatos ambiguos. Las fechas se interpretan explícitamente como día-mes-año. Se conservan importes y monedas originales; la propuesta de comparación utiliza el neto CLP de la fuente. La suma de control de las 541 cabeceras, incluidos todos los estados, es 669.016.915,21 CLP. No se presenta como pago efectivo ni como gasto definitivo.

La regla de Tukey marca 61 órdenes con neto CLP sobre 3.723.495,50 CLP. Ninguna se elimina. El mapa V2 había diagnosticado otra base: el total de OC de las 536 órdenes CLP, con 60 extremos y umbral 4.379.267,38 CLP. La diferencia se explica por variable y población; ambas bases se reproducen en el notebook. Un extremo estadístico no constituye evidencia de error.

5.3. Vista transformada

Se produce una tabla separada de 541 filas con:

- Estandarización Z del neto CLP, con media y desviación poblacional guardadas. Una variable constante retorna cero y no divide por cero.

- Siete columnas one-hot para las cuatro monedas y los tres estados. Se conserva el vocabulario utilizado.
- Tamaño ordinal Micro = 1, Pequeña = 2, Mediana = 3 y Grande = 4. Las 56 órdenes con NoClasificado mantienen NA e indicador.

La vista permite estudiar escalas y categorías en exploraciones posteriores, sin modificar los importes. El ordinal expresa orden, no igualdad de distancias. La clasificación procede del archivo y no se verificó con ventas de los proveedores. Si se realiza modelado predictivo, los parámetros y vocabularios deberán ajustarse solo sobre entrenamiento; esta sumativa no declara un modelo entrenado.

6. Codificación funcional y validación

El pipeline separa lectura, perfil, validación de cabeceras, conversiones, relaciones, diagnóstico de detalle, transformaciones y exportación. Las funciones reciben datos y parámetros y devuelven tablas nuevas; la exportación se concentra en una función. El original se vuelve a verificar al finalizar.

Se ejecutaron 18 pruebas con resultado satisfactorio. Incluyen números con coma, entrada vacía, fechas imposibles, montos contradictorios por OC, conservación de datos, RUT con cero inicial, series constantes, categorías inesperadas y una única categoría nominal. Las pruebas sobre el archivo real exigen conservar 541 órdenes, las tres excepciones de detalle y las cantidades de faltantes.

Los notebooks se ejecutan con kernels nuevos, conservan contadores y salidas y detienen el flujo ante fallos. Después de exportar se recarga la tabla de órdenes; se comprueban claves y montos con tolerancia de 10^{-7} CLP, compatible con los ocho decimales exportados. Esta tolerancia numérica no tiene el mismo propósito que el umbral de 1 CLP utilizado para el diagnóstico de conciliación.

Samuel y Mietchen (2023) muestran que declarar dependencias y disponer de notebooks no basta para asegurar resultados reproducibles. En este proyecto se distingue la ejecución asistida ya realizada de la reconstrucción local y cruzada que todavía debe completar el equipo.

7. Control de versiones y trazabilidad

La revisión inicial del repositorio encontró dos commits de Benjamín, del 8 y 12 de septiembre de 2026: estructura inicial y mapa corregido. Esa evidencia no acredita todavía contribuciones

de los otros integrantes. Los commits de esta base registran trabajo asistido; no se les atribuyen revisiones o autorías inexistentes.

Cada integrante deberá ejecutar y desarrollar tareas propias con identidad real, durante el período de trabajo, y participar en revisiones cruzadas. La bitácora recoge una decisión por fila, con cifras, motivo, impacto y estado. Los identificadores de nuevos commits se incorporarán después de producir los cambios reales.

La guía exige evidencia visible en los notebooks. Por ello, debe retirarse el filtro de nbstripout instalado anteriormente en este repositorio y comprobarse el contenido preparado para el commit. Ver un resultado en Jupyter no prueba que el filtro permita guardarlo en Git.

El acceso compartido al original y a las tablas individuales sigue pendiente. El paquete de trabajo contiene código, informe y resultados agregados para su revisión; no se han publicado archivos ni nuevos commits de esta base. El original y las tablas individuales permanecen locales. La versión final debe resolver el acceso autorizado a esos insumos, las dependencias reconstruibles y el acceso del docente. El entorno virtual y los auxiliares de compilación no se versionan.

8. Vinculación con el mapa conceptual V2

El mapa corregido se mantiene como documento legible en `F1/docs/Mapa_conceptual_Grupo7_V2.pdf`, junto a su editable. La tabla 4 vincula sus conceptos con evidencias; la correspondencia completa está en `docs/vinculacion_mapa.md`.

Tabla 4: Conceptos implementados y trabajo proyectado

Concepto	Estado	Evidencia
Definición y entorno	Implementado; revisión local pendiente	Notebook F1 y configuración.
Adquisición y raw	Lectura/hash implementados; incorporación remota pendiente	F1/data/raw y manifiesto.
Exploración	Implementada	Notebook F2, secciones 2 y 3.
Limpieza y transformación	Implementadas; políticas propuestas	F2/src y parámetros exportados.
Git versiona la limpieza	Base preparada; aportes grupales pendientes	Historia, rama y bitácora.
Jupyter documenta exploración	Implementado con salidas	Notebooks ejecutados.
Rubros	Pertenencia implementada; montos por rubro pendientes	Puente y excepciones de detalle.
Visualización y reporte	Figura diagnóstica e informe borrador	Matplotlib y LaTeX.
F3 y F4	Proyectadas	Sin declarar ejecución ni entregables futuros cerrados.

9. Reflexión técnica y próximos pasos

La decisión central es separar las unidades presentes en el archivo. Validar atributos de cabecera permite obtener una tabla de órdenes sin multiplicar sus importes. Sin embargo, la conciliación de firmas no resuelve todas las multiplicidades del detalle. Esta limitación impide asignar montos por rubro con la evidencia actual, aunque sí permite conservar y estudiar relaciones de pertenencia.

Las alternativas descartadas tienen consecuencias observables: eliminar por actividad perdería 139 órdenes; imputar la moda asignaría información desconocida; deduplicar el detalle de la OC 264 quitaría un millón de CLP. Conservar datos y declarar excepciones produce una base más defendible que presentar esas decisiones como automáticamente resueltas.

Antes de entregar se deben cerrar los siguientes puntos:

1. Validar definición de montos, conversión a CLP y las tres excepciones.
2. Justificar filtro de estados y transformaciones en la bitácora.
3. Resolver acceso autorizado al original y documentar URL/fecha de descarga.
4. Acordar dependencias, ejecutar en Windows y reconstruir en otro equipo.
5. Registrar aportes y revisiones reales de los cuatro integrantes.
6. Completar portada y metadatos docentes; revisar la versión final.

Referencias

- Guía de desarrollo: Evaluación Sumativa 1 (Fases 1 y 2)*. (s. f.). [Documento de apoyo de la asignatura MCDI500 facilitado al equipo].
- NumPy Developers. (s. f.). *numpy.percentile*. NumPy documentation. Recuperado el 13 de septiembre de 2026, de <https://numpy.org/doc/stable/reference/generated/numpy.percentile.html>
- pandas Development Team. (s. f.). *pandas.read_csv*. pandas documentation. Recuperado el 13 de septiembre de 2026, de https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html
- Project Jupyter. (s. f.). *File and output formats*. JupyterLab documentation. Recuperado el 13 de septiembre de 2026, de https://jupyterlab.readthedocs.io/en/stable/user/file_formats.html
- Rúbrica sumativa 1 fase 1 y 2*. (s. f.). [Rúbrica de evaluación de la asignatura MCDI500 facilitada al equipo].
- Samuel, S., & Mietchen, D. (2023). *Computational reproducibility of Jupyter notebooks from biomedical publications* [Prepublicación]. arXiv. <https://doi.org/10.48550/arXiv.2308.07333>