



Universidad Andrés Bello
Magíster en Ciencia de Datos e Inteligencia Artificial

MCDI500
Programación para la ciencia de datos

Evaluación Sumativa 1

Fases 1 y 2

Preparación reproducible de órdenes de Compra Ágil de Valparaíso

Grupo 7

Benjamín Araya Matta
Alan Cañete Calquin
Patricio Cortez Triviño
Jorge Guaico Ortega

Docente: Omar Iván Salinas Silva
Fecha de entrega: 16 de septiembre de 2026
Versión de trabajo: 16 de septiembre de 2026

Primera entrega sumativa F1 y F2

Base preparada con asistencia de herramientas de apoyo; ejecución de F1 y F2 verificada por los integrantes del grupo en Windows 10 y Windows 11.

Repositorio:

<https://github.com/BenjaArayaM/proyecto-grupo7-mcdi500>

Índice

1. Introducción y contextualización	1
2. Problemática, objetivos y alcance	2
2.1. Problema y objetivo general	2
2.2. Objetivos específicos verificables	2
2.3. Supuestos y exclusiones	2
3. Fase 1: entorno y procedencia	3
3.1. Organización reproducible	3
3.2. Herramientas elegidas y versiones	3
4. Fase 2: diagnóstico de la estructura de los datos	5
4.1. Lectura y unidad de observación	5
4.2. Repeticiones y conciliación de detalle	5
4.3. Proveedores y jerarquía de rubros	6
5. Decisiones de preprocesamiento y transformación	6
5.1. Faltantes y alternativas	6
5.2. Importes, fechas y valores extremos	7
5.3. Vista transformada	7
6. Fase 3: modularización y optimización del procesamiento	8
7. Codificación funcional y validación	8
8. Control de versiones y trazabilidad	9
9. Vinculación con el mapa conceptual V2	12
10. Reflexión técnica	13
Referencias	14

1. Introducción y contextualización

El proyecto estudia la preparación de datos de Compra Ágil asociados a la unidad ABASTECIMIENTO de la Municipalidad de Valparaíso. La pregunta del mapa conceptual V2 es cómo se distribuyen los montos de las órdenes de compra según proveedores, rubros y mes de envío. Responderla exige primero establecer unidades de observación, comparabilidad monetaria y calidad de la información.

La copia examinada contiene 11.177 filas y 63 columnas. El diagnóstico distingue 541 órdenes y 277 RUT proveedores, con fechas de envío entre 2025-01-06 y 2025-06-30. Una fila del archivo no equivale necesariamente a una orden ni a un ítem único. Esta diferencia afecta directamente los totales y la interpretación de cualquier gráfico posterior.

La Fase 1 define problema, objetivos y entorno; la Fase 2 obtiene, explora, prepara y valida. Esta delimitación responde a la guía y a la rúbrica suministradas (*Guía de desarrollo*, s. f.; *Rúbrica sumativa 1*, s. f.). El análisis sustantivo y la comunicación final se desarrollarán en las fases posteriores, utilizando las salidas verificadas y manteniendo para F4 las decisiones analíticas que requieren una definición metodológica adicional.

La base recibió inicialmente una validación asistida realizada por Benjamín Araya, utilizando un entorno con Python 3.12.14. Posteriormente, Jorge Guaico realizó una validación local en Windows, seguida por la validación de Alan Cañete y finalmente por la de Patricio Cortez, utilizando entornos con Python 3.13.15. Estas comprobaciones fueron realizadas en equipos con Windows 10 y Windows 11, permitiendo contrastar la ejecución del proyecto entre distintos entornos locales y verificar su reproducibilidad Peng (2011); Sandve et al. (2013).

En la validación final se ejecutaron las seis celdas de código de F1 y las doce celdas de F2 sin errores, conservando sus salidas. Además, las 18 pruebas automatizadas de F2 finalizaron satisfactoriamente. El pipeline de procesamiento generó 541 órdenes a partir de 11.177 filas originales y registró tres excepciones de detalle que quedaron identificadas para revisión.

La ejecución se realizó mediante entornos virtuales locales creados a partir de las dependencias versionadas en el repositorio. El entorno virtual `.venv` no forma parte del repositorio y debe ser recreado por cada integrante al configurar el proyecto en un nuevo equipo. Además, el informe fue compilado localmente mediante MiKTeX.

2. Problemática, objetivos y alcance

2.1. Problema y objetivo general

El problema técnico consiste en convertir una exportación que mezcla cabeceras, ítems y cotizaciones en tablas reproducibles, sin multiplicar importes ni inventar atributos faltantes. El objetivo general es preparar un entorno reproducible y un pipeline de procesamiento que permitan caracterizar la distribución de los montos de las órdenes de compra según proveedores, rubros y mes de envío, conservando la procedencia y trazabilidad de las decisiones.

2.2. Objetivos específicos verificables

1. Documentar intérprete, dependencias, estructura y SHA-256 del original; verificar las rutas requeridas desde la raíz del proyecto.
2. Perfilar el 100 % de las columnas y medir faltantes, repeticiones, monedas, estados y cardinalidades antes de transformar.
3. Construir por código una tabla con clave `codigoOC` única, conservando las órdenes observadas y separando sus relaciones con rubros.
4. Implementar conversiones y políticas justificadas de faltantes, extremos y variables derivadas; registrar parámetros e impacto.
5. Probar casos normales, límites y errores; ejecutar F1 y F2 desde kernels nuevos y relacionar sus evidencias con el informe y los commits efectivos.

2.3. Supuestos y exclusiones

Se limita el estudio a la copia adjunta y su cobertura observada. No se infieren pagos efectivos, irregularidades, causalidad, estacionalidad anual ni resultados representativos de todas las compras públicas del país.

La cabecera de una orden debe tener atributos constantes por código; el pipeline se detiene si encuentra contradicciones. Se propone usar el neto CLP informado por la fuente como medida común, sujeto a contrastar el diccionario monetario. Las órdenes con solicitud de cancelación se conservan y se identifican para una decisión posterior sobre el universo descriptivo.

El archivo contiene únicamente valores SI en `ProveedorSeleccionado`; por ello, no permite una comparación documentada entre ofertas ganadoras y perdedoras. Los montos por rubro quedan condicionados a conciliar el detalle y resolver sus multiplicidades. Esta entrega mantiene las relaciones de pertenencia sin realizar una asignación monetaria entre rubros. La definición y justificación de la regla de asignación de montos por rubro queda pendiente para la Fase 4, donde se abordará como parte del análisis sustantivo final.

Las tres órdenes cuyo detalle no concilia con la cabecera también se mantienen preservadas. En esta etapa no se eliminan ni se redistribuyen sus registros. La definición del tratamiento de estas órdenes en los agregados finales queda pendiente para F4, dejando explícita la consecuencia de la alternativa seleccionada.

3. Fase 1: entorno y procedencia

3.1. Organización reproducible

Se mantiene la estructura F1–F4 existente. El archivo original se conserva en `F1/data/raw/1874020CCompraAgil.csv`. Las salidas transformadas se generan en `F2/data/processed`. El notebook F1 reconoce el archivo sin imputar, limpiar ni exportar registros procesados.

Tabla 1: Componentes y responsabilidad técnica

Componente	Responsabilidad
<code>proyecto.json</code>	Esquema, columnas, hash y políticas parametrizadas.
<code>F1/src/entorno.py</code>	Raíz, integridad y versiones observadas.
<code>F2/src/preprocesamiento.py</code>	Funciones de diagnóstico, preparación y validación.
<code>F2/tests</code>	Pruebas de comportamiento y riesgos analíticos.
<code>evidencias</code>	Entornos, pruebas y ejecución de notebooks.
<code>informe</code>	Texto LaTeX, tablas, figura y PDF.
<code>docs</code>	Plan, bitácora, mapa y matriz de rúbrica.

El original tiene 21.743.181 bytes. Su huella, registrada en la configuración, coincide con la copia empleada para auditar el mapa V2:

[1fcbdec3161500e95a15d2af82df3d007549f2d5da9a6d0b4e6063540406be1c](#)

La ruta usa un nombre canónico; solo renombrar el adjunto no modifica sus bytes. La URL y fecha de descarga originales deben documentarse por quien obtuvo el archivo. No se sustituyen por la fecha de esta validación.

3.2. Herramientas elegidas y versiones

pandas permite declarar separador, codificación y tipos al leer el CSV (pandas Development Team, s. f.). Se utiliza para perfiles, proyecciones y relaciones entre tablas. NumPy calcula cuantiles y parámetros de escala con criterios explícitos (NumPy Developers, s. f.). Matplotlib representa los faltantes por orden a partir de las mismas métricas que alimentan las tablas

del informe. Las funciones operan sobre copias o devuelven objetos nuevos, de modo que la narrativa de Jupyter no oculte mutaciones del original.

JupyterLab permite editar archivos LaTeX y visualizar PDF (Project Jupyter, s. f.). El texto se mantiene en `informe/informe.tex`. El script `scripts/compilar_informe.py` regenera los insumos desde el pipeline y ejecuta tres pasadas de `pdflatex` para actualizar referencias e índice. Benjamín comprobó la disponibilidad de `pdfTeX 1.40.29`, incluido en TeX Live 2026, y comunicó tres pasadas correctas al compilar el borrador en Windows. LaTeX es una dependencia externa al entorno virtual de Python.

La comprobación asistida inicial utilizó Python 3.12.14 en Linux, pandas 2.2.3, NumPy 2.3.5 y Matplotlib 3.10.8. Su ejecución usó `ipykernel` en memoria y un proceso nuevo por notebook debido a las restricciones de conexiones de ese entorno. Las dependencias directas de esa comprobación inicial se conservan en `requirements-validacion.txt`; no describen la ejecución local posterior.

La ejecución posterior en Windows utilizó el kernel `grupo7_mcdi500` y el intérprete de `.venv/Scripts/python.exe`. Las versiones de la tabla 2 provienen de `evidencias/entorno_F1.json` y `evidencias/entorno_F2.json`, coincidentes entre ambas fases.

Tabla 2: Versiones observadas en el entorno local de Windows

Componente registrado	Versión observada
Python	3.13.15
NumPy	2.5.3
pandas	3.0.5
Matplotlib	3.11.1
scikit-learn	1.9.0
nbformat	5.11.1
nbclient	0.11.0
ipykernel	7.3.0
JupyterLab	4.6.3

Nota. El registro de un paquete acredita su presencia, no su uso en cada transformación. Esta entrega no entrena un modelo con `scikit-learn`.

El proyecto mantiene `requirements.txt` como archivo de dependencias para la configuración del entorno de ejecución. La primera validación estable registrada por el equipo se realizó en un entorno con Python 3.12.14 y las versiones indicadas en `requirements-validacion.txt`, archivo que se conserva como evidencia histórica de dicha comprobación. Posteriormente, las validaciones documentadas continuaron en equipos con Windows utilizando Python 3.13.15 y `requirements.txt` para instalar las dependencias del proyecto. En la validación final, la instalación y las dependencias fueron comprobadas satisfactoriamente mediante `pip check`.

4. Fase 2: diagnóstico de la estructura de los datos

4.1. Lectura y unidad de observación

La lectura usa punto y coma, codificación Windows-1252 y campos iniciales como texto. Los vacíos se reconocen como ausentes y los RUT no se convierten a números. La lista de 22 atributos de cabecera se declara en la configuración y se aplica con código desde el original completo.

Antes de proyectar una fila por orden se verifica que esos atributos sean constantes dentro de cada `codigoOC`. La prueba permite construir 541 cabeceras sin repetir sus montos. Este procedimiento no equivale a eliminar indiscriminadamente las filas repetidas del archivo.

Se observan 536 órdenes en CLP, dos en USD, dos en UTM y una en CLF. Los estados son 537 Aceptada, tres Recepción Conforme y una Solicitud de Cancelación. Se conservan todos los registros y una marca identifica las 540 órdenes de los dos primeros estados como propuesta para análisis descriptivo.

4.2. Repeticiones y conciliación de detalle

Hay 6 filas completamente idénticas adicionales, y 12 filas pertenecen a esos grupos. En 2.040 de 2.043 grupos OC–producto, la cantidad de filas coincide con el producto de las firmas distintas de ítem y cotización. En la OC 2427-699-AG25 aparecen 32 firmas de cada lado y 1.024 filas.

La coincidencia es compatible con una expansión cartesiana de relaciones, pero no demuestra por sí sola el mecanismo de exportación. La suma del campo `MontoNetoItemCLP` sobre firmas distintas concilia con la cabecera, a tolerancia absoluta de 1 CLP, en 538 órdenes.

Tabla 3: Órdenes cuyo detalle de firmas distintas no concilia

Orden	Neto OC (CLP)	Suma de firmas	Diferencia
2427-264-AG25	2.000.000,00	1.000.000,00	-1.000.000,00
2427-511-AG25	37.473,00	29.984,00	-7.489,00
2427-543-AG25	1.490.341,00	1.463.816,00	-26.525,00

Nota. Diferencia = suma de firmas menos neto de la OC. Tabla generada por código.

En 2427-264-AG25 existen dos filas idénticas de un millón de CLP y una cabecera de dos millones. Borrar una de esas filas perdería un millón del detalle. Por ello, se preservan las discrepancias, no se exporta un detalle monetario definitivo y se solicita contrastar las tres

órdenes con la fuente. La conciliación monetaria permite verificar consistencia entre los agregados disponibles, pero no demuestra por sí sola que cada línea del detalle corresponda a una línea real de la orden original. La definición de su tratamiento en los agregados finales queda pendiente para F4.

4.3. Proveedores y jerarquía de rubros

Se normalizan espacios, mayúsculas y puntos para comparar RUT y nombres, preservando las columnas originales. No se encontraron RUT asociados a varios nombres normalizados; por tanto, no se justifican fusiones por similitud en esta copia.

Los niveles N1, N2 y N3 contienen 53, 191 y 487 etiquetas. Hay 180 órdenes con más de un N1 y una etiqueta N2 bajo varios padres N1. Se conserva la ruta completa N1–N2–N3 en una tabla de 1.683 relaciones. Esta tabla expresa pertenencia, no asignación de montos. Sus conteos pueden solaparse.

5. Decisiones de preprocesamiento y transformación

5.1. Faltantes y alternativas

La tabla 4 diferencia el denominador de filas del denominador de órdenes. Esta distinción evita trasladar porcentajes de una unidad a otra.

Tabla 4: Ausencias en el original y en las cabeceras

Campo	Filas ausentes	OC ausentes
Actividad del proveedor	2.695 (24,11 %)	139 / 541 (25,69 %)
Región del proveedor	150 (1,34 %)	8 / 541 (1,48 %)
Impuesto específico del ítem	11.177 (100,00 %)	No aplica: campo de ítem

Nota. Filas: $n = 11.177$. OC: $n = 541$. El impuesto específico es un atributo de ítem.

Eliminar órdenes sin actividad dejaría 402 de 541; hacerlo por región dejaría 533. Imputar la moda asignaría, respectivamente, 139 u ocho atributos sin evidencia de la fuente. Se propone conservar los NA y agregar marcas y etiquetas de presentación. El impuesto específico del ítem, completamente vacío, no se interpreta como cero.




Figura 1: Faltantes de atributos de proveedor medidos por orden.

Nota. Elaboración mediante Matplotlib a partir de las métricas de F2.

El neto CLP tiene cero valores faltantes: no se aplica imputación por media, mediana ni grupo. Su varianza poblacional antes y después es 2.326.586.109.020,78 CLP²; el cambio es cero, porque ningún importe fue reemplazado o recortado.

5.2. Importes, fechas y valores extremos

La conversión de números usa coma decimal y rechaza textos o formatos ambiguos. Las fechas se interpretan explícitamente como día-mes-año. Se conservan importes y monedas originales; la propuesta de comparación utiliza el neto CLP de la fuente. La suma de control de las 541 cabeceras, incluidos todos los estados, es 669.016.915,21 CLP. No se presenta como pago efectivo ni como gasto definitivo.

La regla de Tukey marca 61 órdenes con neto CLP sobre 3.723.495,50 CLP. Ninguna se elimina. El mapa V2 había diagnosticado otra base: el total de OC de las 536 órdenes CLP, con 60 extremos y umbral 4.379.267,38 CLP. La diferencia se explica por variable y población; ambas bases se reproducen en el notebook. Un extremo estadístico no constituye evidencia de error.

5.3. Vista transformada

Se produce una tabla separada de 541 filas con:

- Estandarización Z del neto CLP, con media y desviación poblacional guardadas. Una variable constante retorna cero y no divide por cero.

- Siete columnas one-hot para las cuatro monedas y los tres estados. Se conserva el vocabulario utilizado.
- Tamaño ordinal Micro = 1, Pequeña = 2, Mediana = 3 y Grande = 4. Las 56 órdenes con NoClasificado mantienen NA e indicador.

La vista permite estudiar escalas y categorías en exploraciones posteriores, sin modificar los importes. El ordinal expresa orden, no igualdad de distancias. La clasificación procede del archivo y no se verificó con ventas de los proveedores. Si se realiza modelado predictivo, los parámetros y vocabularios deberán ajustarse solo sobre entrenamiento; esta sumativa no declara un modelo entrenado.

6. Fase 3: modularización y optimización del procesamiento

La Fase 3 se orientó a mejorar la estructura técnica del procesamiento desarrollado en las fases anteriores, manteniendo las decisiones y resultados obtenidos en F1 y F2. El trabajo se concentró en la modularización del código, la incorporación de una arquitectura orientada a objetos y la validación automatizada del pipeline.

Como parte de la optimización, se evaluó el comportamiento del procesamiento mediante una comparación entre una implementación basada en bucles y otra basada en operaciones de pandas. La evaluación consideró tiempo de ejecución y memoria utilizada para distintos tamaños de entrada, permitiendo identificar el rango en que cambia el comportamiento relativo de ambas alternativas.

La Fase 3 también incorporó pruebas automatizadas y una reorganización de las responsabilidades del procesamiento, separando componentes asociados al tratamiento de datos, generación de métricas y exportación de resultados. Los resultados detallados de esta implementación y su validación se presentan en las secciones siguientes.

Las decisiones metodológicas relativas a la asignación monetaria por rubro y al tratamiento definitivo de las tres órdenes no conciliadas se mantienen pendientes para la Fase 4.

7. Codificación funcional y validación

El pipeline separa lectura, perfil, validación de cabeceras, conversiones, relaciones, diagnóstico de detalle, transformaciones y exportación. Las funciones reciben datos y parámetros y devuelven tablas nuevas; la exportación se concentra en una función. El original se vuelve a verificar al finalizar.

Se ejecutaron 18 pruebas con resultado satisfactorio. Incluyen números con coma, entrada vacía, fechas imposibles, montos contradictorios por OC, conservación de datos, RUT con cero inicial, series constantes, categorías inesperadas y una única categoría nominal. Las pruebas sobre el archivo real exigen conservar 541 órdenes, las tres excepciones de detalle y las cantidades de faltantes.

Las ejecuciones locales automatizadas utilizaron un kernel nuevo por notebook. `evidencias/ejecucion_F1.json` registra seis celdas de código ejecutadas y cero errores; `evidencias/ejecucion_F2.json` registra doce y cero, respectivamente. Ambos archivos identifican Windows, el motor Jupyter, el kernel utilizado y la conservación de salidas. El resultado de las 18 pruebas se conserva en `evidencias/pruebas_F2.json`.

Los contadores y resultados permanecen visibles en los notebooks versionados. El flujo se detiene ante fallos. Después de exportar se recarga la tabla de órdenes; se comprueban claves y montos con tolerancia de 10^{-7} CLP, compatible con los ocho decimales exportados. Esta tolerancia numérica no tiene el mismo propósito que el umbral de 1 CLP utilizado para el diagnóstico de conciliación.

Samuel y Mietchen (2023) muestran que declarar dependencias y disponer de notebooks no basta para asegurar resultados reproducibles. En este proyecto se distinguen tres alcances: validación asistida inicial, ejecución local en Windows y validaciones posteriores realizadas por los integrantes del grupo en distintos equipos. Estas comprobaciones permitieron contrastar la ejecución del proyecto entre Windows 10 y Windows 11, utilizando Python 3.13.15 en las validaciones locales posteriores a la comprobación inicial.

8. Control de versiones y trazabilidad

El historial Git revisado permite identificar contribuciones sustantivas de los cuatro integrantes del grupo. Para esta síntesis se consideran commits representativos de implementación, validación, documentación técnica y trazabilidad, excluyendo cambios correspondientes únicamente a bitácoras y commits de merge.

Integrante	Commit	Contribución representativa
Benjamín Araya	9b266b2	Crea la estructura inicial del proyecto.
	0a132d4	Agrega el mapa conceptual corregido según retroalimentación docente.
	8b4fcb6	Incorpora la base asistida para revisión del grupo.
	6632bd9	Registra ejecución local de F1 en Windows.
	5a4325e	Registra validación local y resultados de F2.
Alan Cañete	fd1e8d0	Incorpora el dataset utilizado en el proyecto.
	122bb02	Ajusta el tratamiento de la excepción del CSV para incorporar el dataset.
Jorge Guaico	009b81d7	Registra validación local de Jorge en Windows.
Patricio Cortez	ceb01fe	Valida el entorno Python 3.13 y las dependencias de F2.
	aa39e91	Registra la validación de ejecución reproducible de F2.
	5be9729	Registra la ejecución del pipeline de F2.
	621d816	Valida las pruebas automatizadas de F2.
	919e9c1	Registra la validación completa de ejecución de F1 y F2.

Tabla 5: Contribuciones representativas identificadas en el historial Git.

La tabla no pretende representar la totalidad del trabajo realizado por cada integrante, sino evidenciar mediante el historial versionado distintas contribuciones técnicas y de validación realizadas durante el desarrollo.

La ejecución de F1 actualizada quedó incorporada en 45ea1ad, y la de F2 en 5a4325e. El campo `revision_git_al_ejecutar` de cada evidencia corresponde al commit presente al iniciar esa ejecución, que precede al commit que guarda sus resultados. La huella de la fuente del notebook se registra por separado; no se reemplaza aquel identificador por uno posterior.

Los avances documentados acreditan contribuciones individuales de los cuatro integrantes del grupo mediante el historial Git y la bitácora. Benjamín registró la estructura inicial y las primeras validaciones; Alan incorporó y ajustó el tratamiento del dataset; Jorge registró su validación local; y Patricio documentó validaciones de entorno, ejecución reproducible, pipeline, pruebas automatizadas y ejecución completa de F1 y F2. La revisión colectiva de las decisiones y evidencias forma parte de la preparación final del informe.

Se retiró el filtro local de nbstripout y se verificó el contenido preparado para los commits mediante `scripts/verificar_entrega.py` con la opción `--staged`. Esta revisión comprobó la presencia de celdas ejecutadas y salidas; no certifica por sí sola la corrección metodológica ni la calificación del equipo.

El código, los notebooks con resultados, la documentación y las evidencias de validación se encuentran publicados en la rama principal del repositorio. El original y las tablas individuales se mantienen como insumos de trabajo y su tratamiento se documenta mediante los archivos y evidencias disponibles en el repositorio. Las dependencias fueron instaladas y comprobadas en el entorno local utilizado para la validación final, y la ejecución de F1 y F2 fue contrastada en equipos con Windows 10 y Windows 11. El entorno virtual y los auxiliares de compilación no se versionan.

9. Vinculación con el mapa conceptual V2

El mapa corregido se mantiene como documento legible en `F1/docs/Mapa_conceptual_Grupo7_V2.pdf`, junto a su editable. La tabla 6 vincula sus conceptos con evidencias; la correspondencia completa está en `docs/vinculacion_mapa.md`.

Tabla 6: Conceptos implementados y trabajo proyectado

Concepto	Estado	Evidencia
Definición y entorno	Ejecutado y validado en Windows	Notebook F1, configuración y evidencias de ejecución.
Adquisición y raw	Lectura y trazabilidad documentadas; acceso compartido según disponibilidad de los insumos	F1/data/raw y manifiesto.
Exploración	Implementada y validada	Notebook F2, secciones 2 y 3.
Limpieza y transformación	Implementadas y validadas	F2/src, parámetros exportados y evidencias del pipeline.
Git versiona la limpieza	Código, resultados, documentación y aportes técnicos versionados	Commits de la tabla 5 y bitácora.
Jupyter documenta exploración	Implementado con salidas conservadas	Notebooks ejecutados y evidencias de ejecución.
Rubros	Pertenencia implementada; asignación de montos por rubro mantiene excepciones identificadas	Puente, métricas y excepciones de detalle.
Visualización y reporte	Figura diagnóstica e informe LaTeX en desarrollo	Matplotlib, LaTeX y script de compilación.
F3 y F4	F3 y F4 posteriores a esta entrega	Las fases posteriores contemplan la profundización técnica, el análisis sustantivo y la definición de las decisiones metodológicas pendientes, reservadas para F4.

10. Reflexión técnica

La decisión central es separar las unidades presentes en el archivo. Validar atributos de cabecera permite obtener una tabla de órdenes sin multiplicar sus importes. Sin embargo, la conciliación de firmas no resuelve todas las multiplicidades del detalle. Esta limitación impide realizar en esta etapa una asignación monetaria defendible por rubro. Por ello, F1 y F2 mantienen las relaciones de pertenencia y documentan las excepciones sin forzar una distribución de montos. La regla de asignación y el tratamiento definitivo de las órdenes no conciliadas quedan como decisiones analíticas para F4, donde deberán justificarse y aplicarse de manera reproducible.

Las alternativas descartadas tienen consecuencias observables: eliminar por actividad perdería 139 órdenes; imputar la moda asignaría información desconocida; deduplicar el detalle de la OC 264 quitaría un millón de CLP. Conservar datos y declarar excepciones produce una base más defendible que presentar esas decisiones como automáticamente resueltas.

Referencias

- Guía de desarrollo: Evaluación Sumativa 1 (Fases 1 y 2)*. (s. f.). [Documento de apoyo de la asignatura MCDI500 facilitado al equipo].
- NumPy Developers. (s. f.). *numpy.percentile*. NumPy documentation. Recuperado el 13 de septiembre de 2026, de <https://numpy.org/doc/stable/reference/generated/numpy.percentile.html>
- pandas Development Team. (s. f.). *pandas.read_csv*. pandas documentation. Recuperado el 13 de septiembre de 2026, de https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html
- Project Jupyter. (s. f.). *File and output formats*. JupyterLab documentation. Recuperado el 13 de septiembre de 2026, de https://jupyterlab.readthedocs.io/en/stable/user/file_formats.html
- Rúbrica sumativa 1 fase 1 y 2*. (s. f.). [Rúbrica de evaluación de la asignatura MCDI500 facilitada al equipo].
- Samuel, S., & Mietchen, D. (2023). *Computational reproducibility of Jupyter notebooks from biomedical publications* [Prepublicación]. arXiv. <https://doi.org/10.48550/arXiv.2308.07333>
- Peng, R. D. (2011). Reproducible research in computational science. *Science*, 334(6060), 1226–1227. <https://doi.org/10.1126/science.1213847>
- Sandve, G. K., Nekrutenko, A., Taylor, J., & Hovig, E. (2013). Ten simple rules for reproducible computational research. *PLoS Computational Biology*, 9(10), e1003285. <https://doi.org/10.1371/journal.pcbi.1003285>